BLOCK 01 · PROJECT OVERVIEW

LogiFlow *Intelligence*

Internal copilot cho team vận hành logistics – pilot tại một hub miền Bắc.

BÀI TOÁN

Giảm coordination overhead và lookup time trong luồng vận hành hàng ngày — stitch dữ liệu đa hệ thống + grounded answer từ SOP, để con người tập trung vào việc thật sự cần phán đoán.

3 USER · THEO PRIORITY

MVP · T1–T6	CS Team 20 người pilot · ~70% traffic	Status lookup < 3s · draft reply · auto-classify
PHASE 2 · T7–T9	Điều phối viên Exception handling	SOP tổng hợp · playbook · flag escalate
PHASE 3 · T10+	Quản lý vận hành KPI & review	Tóm tắt ca · drill-down anomaly

30–40% ↓ AHT MỤC TIÊU

3–5 ngày ONBOARD MỚI

×10 PEAK TẾT

BỐI CẢNH & RÀNG BUỘC

6 hệ thống · narrow MVP 3/6

HỆ THỐNG	OMS	TMS + GPS	CARRIER API	CRM / TICKET	SOP REPO · WMS
Phase MVP	Source of truth cho đơn & trạng thái logic. MVP · T1–T6	Vị trí xe real-time, track tuyến giao. MVP · T1–T6	J&T, GHTK — top 1–2 partner. MVP · T1–T6	Phân loại + draft reply cho ticket. Phase 2 · T7–T9	RAG cho exception · hub-level picking. Phase 2–3

4 RÀNG BUỘC LỚN NHẤT

01
Multi-system lag

OMS ↔ TMS trễ 30s–5 phút. Agent luôn gắn "as of" timestamp, không tự kết luận.

02
Peak rõ rệt

6–9h pickup · 14–17h last-mile. Tết / 11.11 / 12.12 có thể ×8–10 baseline.

03
Wrong > no answer

Sai info → refund + NPS giảm + dispute COD. Citation & "I don't know" path là bắt buộc.

04
RBAC & data leak

Hub A không thấy hub B. Filter `role + department_id` ở API Gateway, trước LLM.

MỨC NHẠY CẢM DỮ LIỆU · CAO

PII (tên · SĐT · địa chỉ) + giá cước hợp đồng + vị trí real-time.

PDPA VIỆT NAM | DATA RESIDENCY

KIẾN TRÚC TRIỂN KHAI

Hybrid – *Data Sovereignty Defense*

VPC | CLOUD LLM

User · CS / Dispatcher — UI

↓

API Gateway + Auth · RBAC (role + department_id) — VPC

↓

PII Pseudonymization · Presidio + VN regex
Redis · TTL 30 min · F1 phone 0.95 / name 0.90 / addr 0.85 — VPC BIÊN

↓

Orchestrator + Redis Cache · tool-planner max 5 turns — VPC

Tool Layer
OMS · TMS · Carrier

Denormalized Read
pgvector · BGE-M3 · async 30-60s

↓

LLM · Claude Haiku 70% / Sonnet 30% — CLOUD

↓

De-tokenize → Response UI — VPC BIÊN

4 LÝ DO · DEFENSE RÕ

01 Data Sovereignty, không chỉ PII
"Core data không ra khỏi VN" mạnh hơn "chúng tôi dùng AWS" — differentiator với B2B lớn & khối nhà nước.

02 PII & đơn hàng ở VPC
Orchestrator, cache, vector DB nội bộ. Chỉ prompt đã tokenized ra cloud.

03 Cloud LLM không CapEx
Claude Haiku $1/$5 + Sonnet $3/$15 per MTok (4/2026). Chưa cần đội GPU.

04 Đường rút lui
> 1M tokens/ngày → self-host 7–8B (Qwen/Llama) cho classifier. Cuối: full vLLM on-prem nếu legal flag.

TRADE-OFF THỪA NHẬN
Cross-zone latency +20–50ms · one-time eng +2–3 tuần · ops team hiểu cả 2 zone.

COST ANATOMY · MVP → GROWTH

Không có một cost driver duy nhất.

Budget theo dõi cả ba: **tokens**, **integration ops**, **engineering time**.

MVP

1 HUB · 20 CS · 500–1K REQ/NGÀY

Pilot sizing

LLM API (Haiku 70% + Sonnet 30%)	$60–100
Local embedding · BGE-M3 CPU	~$10
Vector DB · pgvector self-host	$0–20
Compute · orchestrator + Redis	$50–80
Network & hidden infra	$100–150
Monitoring · Langfuse starter	$30–50
Eval pipeline · RAGAS weekly	$50–100
Steady-state / tháng	**$300–510**
Engineering one-time · 4–6 tuần × 2 eng	$8–15K
Integration setup · OMS + TMS + 1–2 carrier	$3–5K

YEAR-1 ALL-IN (AMORTIZED)

$1.4–2.4K / tháng

Growth

150 CS · 5–10K REQ/NGÀY · PEAK ×10

3 use case · multi-hub

LLM API sau optimize (−70% raw)	$500–750
Vector DB HA · Qdrant on-prem	$100–200
Compute · multi-instance + local 7B	$500–800
Integration maintenance	$800–2,500
Carrier stability surcharge	$0–1,000
Human review · 5% escalation	$200–500
Network / infra overhead	$200–400
Monitoring + alerting	$100–200
Eval pipeline ongoing	$150–300
Total Growth / tháng	**$2,550–6,650**

DOMINANT DRIVER THEO GIAI ĐOẠN

MVP	Growth	Peak
Engineering	LLM + Integration	Integration spike

Hidden costs: retry overhead ×1.3–1.5 · guardrail +10–20% · tool-loop blowup · carrier schema drift · PII infra · on-call · eval ongoing.

6 LỚP · KHÔNG CHỈ LLM

Stack giảm ~ *70–80%* LLM calls

vs baseline all-Sonnet

CHIẾN LƯỢC KHÔNG CHỌN

Self-host LLM (chưa break-even) · fine-tuning (overkill) · prompt compression (marginal sau caching)

LAYER 01 — -40-60% input

Prompt caching

System prompt + SOP context + tool schema → cached. 90% off input sau cache write. TTL 5 phút conv · 1 giờ SOP.

Trade-off · 1.25× write đầu; pay-off sau 1 read.

LAYER 02 — -80% traffic

Fast-path template routing

Top 20–30 query patterns (status lookup) match regex/template → trả thẳng từ denormalized view, không qua LLM.

Trade-off · template maintenance; patterns top ổn định.

LAYER 03 — -40-50% slow-path

Prefetch on conversation open

CS click conversation → async prefetch order status → cache trước khi hỏi.

Trade-off · prefetch waste ~5–10% khi không hỏi.

LAYER 04 — -15-25% cost

Semantic cache + event invalidation

SOP hit 50–70% · intent 40–60% · order status 5–15%. Webhook OMS/TMS purge cache, không chỉ TTL.

Trade-off · cache correctness phụ thuộc webhook.

LAYER 05 — -47% vs all-Sonnet

Model routing · Haiku ↔ Sonnet

Haiku 80%: status reasoning · classify · draft. Sonnet 20%: exception · policy interpretation.

Trade-off · misroute → auto-escalate Sonnet nếu conf. thấp.

LAYER 06 — cost ceiling

Max-turn restriction

Hard limit 5 `tool calls/query`. Chạm limit → partial + "I don't know, vui lòng check trực tiếp".

Trade-off · mất case phức tạp → escalate human.

Lever lớn nhất là **prompt caching** — Anthropic native, 90% off cached input.

Anthropic · 4/2026

RELIABILITY & SCALING

SLA, error budget, playbook khi đỏ.

METRIC	TARGET	BUDGET / THÁNG
Availability	99.5%	~3.6h downtime
Correctness	≥ 95%	5% sai
Latency P95	< 3s	5% slow
"I don't know" rate	2–8%	Out-of-band alert
Tool calls / query	P99 ≤ 5	Alert nếu P95 > 4

POLICY · Burn > 50% budget → freeze feature work, fix reliability trước.

CORRECTNESS · FIRST-CLASS

① **Citation** — order_id + system + timestamp · không citation = block.

② **Inconsistency** — trả `INCONSISTENT_DATA`, agent không tự quyết.

③ **Show source, not conclusion.**

④ **Golden set 200 câu** + RAGAS weekly + regression gate.

⑤ **Runtime hallucination detect** — order_id khớp query.

3 FAILURE SCENARIOS · PLAYBOOK

① LLM PROVIDER DOWN

Multi-provider fallback

Claude → GPT → cached → handoff banner. Circuit breaker · health probe 30s.

② PEAK 5–10× (TẾT · 11.11 · 12.12)

Peak Mode + request queue

AI tắt tool-calls live, serve từ denormalized cache. Pre-warm hot orders · auto-scale replicas.

③ BACKEND CHẬM / SAI

Circuit breaker per-tool

Serve cached data + staleness warning · read-replica · async refresh.

DATA FLYWHEEL · HUMAN-GATED

Thumbs-down + "Correct this" → review queue (QA duyệt, **không auto-apply**) → Gold Dataset → regression test.

MONITORING

Availability · Correctness (RAGAS) · Latency per tool · Cost per route · Quality.

TRACK RECOMMENDATION

Track 02 – *AI Infrastructure & Data*

DEFENSE

"Ưu tiên ổn định xương sống (Infra + Data + FinOps) trước khi nâng cấp trí tuệ. Xương sống yếu thì multi-modal chỉ thêm vector failure."

DOMINANT CONCERN	MVP → GROWTH	TRACK WIN
Engineering effort	Data pipeline + integration	TRACK 2
Cost driver	LLM + integration maintenance	TRACK 2
Reliability concern	Throughput + correctness at scale	TRACK 2
Quality concern	Eval infra + drift detection	TRACK 2 / 3
Multi-modal	Phase 3+ · ảnh giao hàng, voice	TRACK 3

ROADMAP PHASE 2 · 4 TUẦN

TUẦN 01
Baseline & Read Model
Đo AHT · đếm query pattern · denormalized read model · BGE-M3 embedding ops.

TUẦN 02
Eval Infra & Golden Set
200 câu golden · RAGAS integration · PII F1 benchmark · correctness first.

TUẦN 03
Cost & A/B Experiments
Cost dashboard · test caching, routing, max-turn, prompt caching · load test peak.

TUẦN 04
CI/CD & LLMOps
Prompt versioning · eval gate · canary deploy · operational runbook.

KỸ NĂNG CẦN BÙ

Lakehouse · Data pipeline · BGE-M3 · Presidio · GPU FinOps · LLMOps CI/CD · RAGAS · **PDPA VN**.

NEXT STEP

SOP cleanup 1 tuần · Legal review T1 · Hire ops engineer part-time.